

## 1 Empirikus közép (átlag)

Legyen adott  $\xi_1, \xi_2, \dots, \xi_n$  minta. A mintákat felhasználva a következőképpen számolható ki az empirikus közép:

$$\bar{\xi} = \frac{\xi_1 + \xi_2 + \dots + \xi_n}{n} \quad (1)$$

## 2 Empirikus és korrigált empirikus szórásnégyzet

Legyen adott  $\xi_1, \xi_2, \dots, \xi_n$  minta. A mintákat felhasználva a következőképpen számolható ki az empirikus szórásnégyzet:

$$s_n^2 = \frac{1}{n} \cdot \sum_{i=1}^n (\xi_i - \bar{\xi})^2 \quad (2)$$

valamint a korrigált empirikus szórásnégyzet:

$$s_n^{2*} = \frac{1}{n-1} \cdot \sum_{i=1}^n (\xi_i - \bar{\xi})^2 \quad (3)$$

## 3 Illeszkedésvizsgálat

Legyen:

- $\xi_1, \xi_2, \dots, \xi_n$  események egy tetszőleges  $A$  eseménytérén
- $k_i$ :  $\xi_i$  esemény bekövetkezéseinek száma,
- $N$ :  $k_1 + k_2 + \dots + k_n$ ; összes bekövetkezés száma,
- $p_i$ :  $\xi_i$  esemény valószínűsége,
- $n$ : események száma,

akkor az illeszkedés vizsgálat az alábbi módon hajtható végre:

$$\chi^2 = \sum_{i=1}^n \frac{(k_i - N \cdot p_i)^2}{N \cdot p_i} \quad (4)$$

Ha kiszámoltuk  $\chi^2$  értékét, össze kell azt vetnünk a  $\chi^2$  táblázattal. A pontosság általában 95%, ebben az esetben a 0.05-ös oszlopból kell kinézni a megoldást ( $1 - 0.95 = 0.05$ ). A feladatban a szabadsági fok  $n - 1$ , ebben a sorban kell vizsgálni a táblázatot. Ha a számított  $\chi^2$  kisebb mint a táblázatban található, akkor a becslést elfogadjuk.

Pro tipp: R-ben a  $\chi^2$  táblázatos ellenőrzés végrehajtható a `qchisq(p=.95, df=n-1)` paranccsal, ami visszaadja a számot amihez egyeztetni kell a számolt  $\chi^2$  értékünket. Értelemszerűen a `p` paraméter a pontossági fokot, míg a `df` paraméter a szabadsági fokot adja meg.

## 4 Homogenitásvizsgálat

Legyen:

- $\xi_1, \xi_2, \dots, \xi_r$  és  $\eta_1, \eta_2, \dots, \eta_r$  események (Figyelem,  $r$  darab van mind a két mintasorban),
- $\xi_i$  egy gyakoriság a  $\xi$  mintában (pl  $\xi_3 = 10$ ),
- $\eta_i$  egy gyakoriság az  $\eta$  mintában (pl  $\eta_5 = 3$ ),
- $n = \xi_1 + \xi_2 + \dots + \xi_r$ ,
- $m = \eta_1 + \eta_2 + \dots + \eta_r$ .

ekkor a homogenitás vizsgálat a következőképpen írható le:

$$\chi^2 = \sum_{i=1}^r \frac{\left(\frac{\xi_i}{n} - \frac{\eta_i}{m}\right)^2}{\frac{\xi_i}{n} + \frac{\eta_i}{m}} \cdot n \cdot m \quad (5)$$

Ha kiszámoltuk  $\chi^2$  értékét, össze kell azt vetnünk a  $\chi^2$  táblázattal. A pontosság általában 95%, ebben az esetben a 0.05-ös oszlopból kell kinézni a megoldást ( $1 - 0.95 = 0.05$ ). A feladatban a szabadsági fok  $r - 1$ , ebben a sorban kell vizsgálni a táblázatot. Ha a számított  $\chi^2$  kisebb mint a táblázatban található, akkor a becslést elfogadjuk.

## 5 Függetlenségvizsgálat

Legyen:

- $A_1, A_2, \dots, A_r$  szempontok,
- $B_1, B_2, \dots, B_s$  szempontok,
- $K_{1,1}, K_{1,2}, \dots, K_{r,s}$  megfigyelések számai, amikor A és B teljesül egyszerre (pl  $K_{3,2} = A_3$  és  $B_2$  is teljesül),
- $N_{i,.} = K_{i,1} + K_{i,2} + \dots + K_{i,s}$ , az A gyakorisága,
- $N_{.,j} = K_{1,j} + K_{2,j} + \dots + K_{r,j}$ , a B gyakorisága,
- $n = N_{1,.} + N_{2,.} + \dots + N_{r,.} = N_{.,1} + N_{.,2} + \dots + N_{.,s}$ , peremértékek összege az oszlopokban és a sorokban megegyezik.

Szemléltetés:

	$B_1$	$B_2$	$B_3$	$N_{i,.}$
$A_1$	$K_{1,1}$	$K_{1,2}$	$K_{1,3}$	$N_{1,.}$
$A_2$	$K_{2,1}$	$K_{2,2}$	$K_{2,3}$	$N_{2,.}$
$N_{.,j}$	$N_{.,1}$	$N_{.,2}$	$N_{.,3}$	$n$

A jelölések bevezetése után a következő képletet használjuk:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{\left( N_{i,j} - \frac{N_{i,.} \cdot N_{.,j}}{n} \right)^2}{\frac{N_{i,.} \cdot N_{.,j}}{n}} \quad (6)$$

Ha kiszámoltuk  $\chi^2$  értékét, össze kell azt vetnünk a  $\chi^2$  táblázattal. A pontosság általában 95%, ebben az esetben a 0.05-ös oszlopból kell kinézni a megoldást ( $1 - 0.95 = 0.05$ ). A feladatban a szabadsági fok  $(r - 1) \cdot (s - 1)$ , ebben a sorban kell vizsgálni a táblázatot. Ha a számított  $\chi^2$  kisebb mint a táblázatban található, akkor a becslést elfogadjuk.

## 6 Lineáris regresszió

Legyenek adottak az  $X = x_1, x_2, \dots, x_n$  és a hozzá tartozó  $Y = y_1, y_2, \dots, y_n$  koordináták. Az ezen pontokat közelítő egyenes egyenlete  $f(x) = \hat{a} + \hat{b}x$ , ahol

$$\hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{X})^2} \quad (7)$$

$$\hat{a} = \bar{Y} - \hat{b} \cdot \bar{X} \quad (8)$$

## 7 Exponenciális regresszió

Az exponenciális regresszió akkor használatos, ha a minta jobban hasonlít egy exponenciális függvény görbéjére mint egy egyenesre. Hasonlóan a lineáris regresszióhoz, itt is egy  $X = x_1, x_2, \dots, x_n$  és  $Y = y_1, y_2, \dots, y_n$  mintapárral dolgozunk.

Maga az exponenciális görbe a következő képlettel írható le:

$$f(x) = a \cdot e^{bx} \quad (9)$$

Hogy megkapjuk a képletben szereplő  $a$  és  $b$  paramétereket, a mintát először vissza kell vezetnünk lineáris regresszióra. Ennek a képlete a következő:

$$f(x) = a_0 + a_1x \quad (10)$$

Az így előállított egyenes segítségével fogjuk megmondani az  $a$  és  $b$  paramétereket:

$$a = e^{a_0}, \quad b = a_1 \quad (11)$$

A regressziós egyenes megszerkesztéséhez ki kell számolnunk az  $a_0$  és  $a_1$  paramétereket. A számolás valójában itt kezdődik, az eredményeket felhasználva eljutunk a 11-es, majd végül a 9-es képlethez. A számolás előtt vezessük be a következő jelölést:

- $Z = \ln(Y)$ , exponenciális alapú, logaritmikusan transzformált  $Y$  koordináták

A számolás elkezdhető:

$$a_1 = \frac{n \cdot \sum z_i x_i - \sum z_i \sum x_i}{n \cdot \sum x_i^2 - (\sum x_i)^2} \quad (12)$$

$$a_0 = \bar{Z} - a_1 \bar{X} \quad (13)$$

Az így kapott  $a_0$  és  $a_1$  paraméterek behelyettesíthetők a 11-es képletbe. Az így megkapott  $a$  és  $b$  paraméterek behelyettesíthetők a 9-es képletbe, ezzel megkapva a közelítő görbét.